

AVANTI BOOTCAMP 2026.2: MACHINE LEARNING

Atividade 1: Conceitos básicos de machine learning

Aluno: Ian Nogueira

Questões:

1. Explique, com suas palavras, o que é machine learning?
2. Explique o conceito de conjunto de treinamento, conjunto de validação e conjunto de teste em machine learning.
3. Explique como você lidaria com dados ausentes em um conjunto de dados de treinamento.
4. O que é uma matriz de confusão e como ela é usada para avaliar o desempenho de um modelo preditivo?
5. Em quais áreas (tais como construção civil, agricultura, saúde, manufatura, entre outras) você acha mais interessante aplicar algoritmos de machine learning?

Respostas:

1. Machine Learning é uma subárea de inteligência artificial que busca trabalhar com dados onde um computador “aprende” estas informações para extrair insights, detectar padrões e utilizar este aprendizado para resolver tarefas de forma “autônoma”. É o estudo de métodos estatísticos e projeção de algoritmos potentes para identificar padrões em dados, aprender com estes e ser utilizado em diversas aplicações.
2. Conjunto de treinamento é a parte dos dados que vai ser utilizado para treinar um modelo de machine learning, é de onde a máquina (ou computador) aprende o que ela tem que aprender, de acordo com o algoritmo utilizado; geralmente contém informações valiosas para o treinamento, se supervisionado. Conjunto de validação trata de validar o aprendizado realizado através do conjunto de treinamento, é através dele que o modelo pode ser analisado sobre a generalização, permitindo comparar abordagens e até mesmo modelos diferentes; ele vai informar como o modelo está lidando com dados ainda não vistos, e torna possível ajustar os hiperparâmetros (como taxa de aprendizado, épocas, camadas, etc) do modelo, por informar como ele está performando. Conjunto de testes é o conjunto de teste definitivo, e contém dados que o modelo não viu em nenhum momento durante ou treinamento ou validação, servem como comparativo para os resultados e saídas do modelo e permitem a utilização de métricas de avaliação dos modelos.
3. Depende do tipo de dado, do contexto da base e do modelo; Existem diversas abordagens, é possível remover se forem de número baixo comparado aos dados completos, mas também é possível gerar novos dados

sintéticos para aquela variável específica, se for necessário, ou novas instâncias totalmente sintéticas, por exemplo.

4. Matriz de confusão é uma ferramenta que mapeia todos os resultados de um modelo preditivo em uma matriz 2x2; são eles: Verdadeiro Positivo, Falso Positivo, Verdadeiro Negativo e Falso Negativo. Esses números além de possibilitarem a visualização de como o modelo está performando, também permitem a realização de cálculos que geram métricas como a acurácia, precisão e recall, que são consideradas padrão para a avaliação de classificadores.
5. Todas!!!!!! Machine learning é uma paixão minha desde que entrei na área da TI e na faculdade, sempre tive interesse no uso de processamento de imagens na área da Física e Astronomia, como detecção e classificação de elementos espaciais. Também é muito interessante ver as possibilidades de uso na área médica, evidenciando o uso plural da área. Atualmente, a área de aplicação que mais acho interessante é a linguística, com o processamento de linguagem natural e a tradução automática.